2026年度

機械学習演習

第2回：二次形式・共分散行列・主成分分析

計良 宥志

本日の内容

1. **復習と $X^\top X$ の性質**：二次形式・対称・半正定値・$X^\top X$ vs $XX^\top$
2. **分散最大化 → PCA**
3. **演習課題（実装）**：固有値分解・`sklearn.PCA`・Iris

1. 復習と $X^\top X$ の性質

二次形式の最大化（復習）

問題

$M \in \mathbb{R}^{n \times n}$ を対称行列とする.

$$\max_{x \in \mathbb{R}^n} x^\top M x \quad \text{s.t.} \quad \|x\|_2^2 = 1$$

$M = X^\top X$ の性質

- Mは対称行列
- Mは正定値．つまり，任意のxに対して，$x^\top M x \geq 0$が成立．
- Mの固有値は全て実数で，異なる固有ベクトルは互いに直行．

$X^\top X$ と $XX^\top$ の意味

機械学習の文脈で理解する.

$$X = \begin{pmatrix} \boldsymbol{x}_1^\top \\ \vdots \\ \boldsymbol{x}_m^\top \end{pmatrix} = \begin{pmatrix} X_1 & \cdots & X_n \end{pmatrix} \in \mathbb{R}^{m \times n}$$ （n次元のデータが m サンプル）

2つの共分散行列

$$X^\top X = \left(X_i^\top X_j\right)_{ij} \in \mathbb{R}^{n \times n} \quad \text{（特徴の共分散行列）}$$

$$XX^\top = \left(\boldsymbol{x}_i^\top \boldsymbol{x}_j\right)_{ij} \in \mathbb{R}^{m \times m} \quad \text{（サンプルの共分散行列）}$$

2. 分散最大化と PCA

中心化

前処理

> 各特徴の平均を引く：$\bar{x}_j = \frac{1}{m}\sum_i x_{ij}$ として $x_{ij} \leftarrow x_{ij} - \bar{x}_j$

以降 X は**中心化済み**とする（各列の平均が 0）

分散最大化

射影（各データをある1側面で見る）

方向 $w \in \mathbb{R}^n$（$\|w\| = 1$）への射影：$z_i = w^\top \boldsymbol{x}_i$

射影の分散（各データごとの違いが出てほしい）

$$\mathrm{Var}(z) = \frac{1}{m}\sum_{i=1}^{m} z_i^2 = \frac{1}{m}\sum_i (w^\top \boldsymbol{x}_i)^2 = w^\top \left(\frac{1}{m} X^\top X\right) w$$

分散を最大化する方向

$$\max_{\|w\|=1} \; w^\top \frac{1}{m} X^\top X\, w$$

PCA まとめ

第 k 主成分

$\frac{1}{m}X^\top X$（= 標本共分散行列）の第 k 固有ベクトル v_k

寄与率

固有値 λ_k が射影方向 v_k での分散に対応

$$\text{寄与率} = \frac{\lambda_k}{\sum_j \lambda_j}$$

次元削減

上位 d 個の固有ベクトル $V_d = (v_1, \ldots, v_d)$ で $Z = XV_d \in \mathbb{R}^{m \times d}$

演習課題（実装）

課題1　2 次元の適当なデータ（例：楕円状）を生成し，ランダムな回転＋ノイズで n 次元（$n \geq 5$）にリフトして X を作れ.

1. 中心化して $M = \frac{1}{m} X^\top X$ を計算
2. `np.linalg.eigh` で固有値分解
3. 上位 2 固有ベクトルで射影し 2D 散布図をプロット

課題2　課題1 の結果と `PCA(n_components=2).fit_transform(X)` が一致する（符号反転を除き）ことを確認せよ.

課題3　`sklearn.datasets.load_iris` を PCA で 2 次元に射影し，クラスごとに色分けして散布図を描け．寄与率も計算し，上位2成分でどの程度の情報を保持できるか確認せよ．

ヒント（有用な関数）
`np.linalg.eigh` / `np.cov` / `PCA` / `matplotlib.pyplot.scatter` / `explained_variance_ratio_`

課題

- 演習課題1〜3をMoodleでまとめて提出（IPython Notebook形式）.

機械学習の分類

機械学習の3つのアプローチ

機械学習は「学習のさせ方」で大きく3つに分かれる

1. **教師あり学習**：入力 x と正解 y のペアから，$x \mapsto y$ の関数を学習
2. **教師なし学習**：正解ラベルなし．データ x のみから構造を発見
3. **強化学習**：行動に対する報酬だけで，最適な方策を学習

教師あり学習の下位分類

回帰（Regression）

出力 y が**連続値**（実数）．予測値と正解のズレ（MSE 等）を最小化

- 例：気温予測，株価予測，売上予測

分類（Classification）

出力 y が**離散ラベル**（カテゴリ）．交差エントロピー等を最小化

- 例：画像認識，感情分析，スパム判定

教師なし学習の下位分類

クラスタリング

データを類似度に基づいてグループに分ける（グループ自体を発見）

- 例：顧客セグメンテーション，文書のトピック分類

次元削減

情報をなるべく保ちつつ，少数の軸にまとめる（**今日の本題！**）

- 例：PCA による可視化，ノイズ除去

異常検知

「正常」の分布を学習し，そこから外れたデータを検出

強化学習

構成要素

- **状態** s：エージェントが観測する環境の情報
- **行動** a：エージェントが選択する動作
- **報酬** r：行動の良し悪しを示すスカラー値
- **方策** $\pi(a \mid s)$：状態から行動への写像（これを学習）

教師あり学習との違い：「正解の行動」は与えられない．試行錯誤で報酬を最大化する方策を獲得

- 例：ゲームAI，ロボット制御，RLHF（ChatGPT 等）

クイズ：どの機械学習で実現できる？

Q1. 写真に写った個人を認識したい

Face Recognition

A1. 分類（顔認識）

教師あり学習・分類
入力：顔画像　／　出力：人物ID（離散ラベル）　／　損失：交差エントロピー

- 顔画像 → 人物名の関数を学習する
- 大量の顔写真＋名前のペアで訓練し，未知の顔にも対応させる
- スマホのロック解除，写真アプリの自動タグ付け などに応用

Q2. 画像の領域を区分けしたい

Segmentation

A2. 分類（セグメンテーション）

教師あり学習・分類（ピクセルごと）
入力：画像　／　出力：各ピクセルのカテゴリマップ　／　損失：ピクセルごとの交差エントロピー

- 通常の分類：画像1枚 → ラベル1個
- セグメンテーション：画像1枚 → **ピクセル数ぶんのラベル**（各ピクセルに「空・道路・人」等を割り当て）
- 正解データとして，ピクセルごとに色分けされたマスク画像を用意
- 自動運転（道路・歩行者の認識），医療画像（臓器の領域特定）などに応用

Q3. 明日の最高気温を予測したい

Temperature

A3. 回帰

教師あり学習・回帰
入力：過去の気象データ　／　出力：気温（連続値）　／　損失：MSE

- 気象データ → 気温（実数）を返す関数を学習する
- 出力が離散ラベルではなく**連続値**なので回帰
- day3 で扱う最小二乗法もこの枠組み
- 株価予測，売上予測，需要予測 などに応用

Q4. 大量の顧客を購買傾向でグループ分けしたい

Clustering

A4. クラスタリング

教師なし学習・クラスタリング
入力：顧客の購買履歴　／　出力：グループID（正解ラベルなし）

- 「似ている顧客は同じグループ」という構造をデータだけから抽出
- 分類との違い：分類はグループが**事前に決まっている**が，クラスタリングは**グループ自体を発見**する
- 顧客セグメンテーション，文書のトピック分類 などに応用

Q5. 工場の製品ラインで不良品を自動検出したい

Defect Detection

A5. 異常検知 or 分類

教師あり・分類 or **教師なし・異常検知**
入力：製品の画像やセンサ値　／　出力：正常 or 不良

- 不良品ラベルが十分にある → **分類**（正常 vs 不良）
- 不良品が稀でラベルが足りない → **異常検知**（正常だけで学習し，外れたものを検出）
- 同じ「不良品検出」でも，**データの状況で手法が変わる**のがポイント
- クレジットカードの不正検知，ネットワーク侵入検知 なども同じ構図

Q6. ロボットアームに物をつかませたい

Robot Arm

A6. 強化学習

強化学習
観測 s：カメラ画像・関節角度　／　行動 a：モータ制御　／　報酬 r：つかめたか

- 「正解の動き」は教えてもらえない → 試行錯誤で方策 $\pi(a \mid s)$ を獲得
- 何度もつかむ動作を繰り返し，成功/失敗の報酬だけで学習
- ゲームAI，自動運転 なども同じ枠組み

Q7. 高次元の遺伝子データから特徴を要約したい

Gene Expression

A7. 次元削減（PCA 等）

教師なし学習・次元削減（今日の本題！）
入力：数万次元の遺伝子発現量　／　出力：少数の主成分

- 数万次元 → 2〜3次元に圧縮して散布図で可視化，など
- 「どの方向にデータが最もばらついているか」を見つけるのが鍵
- 可視化，ノイズ除去，前処理として広く使われる

Q8. チャットボットの応答品質を改善したい

Chatbot RLHF

A8. 強化学習（RLHF）

強化学習（RLHF: Reinforcement Learning from Human Feedback）
状態 s：会話履歴　／　行動 a：応答文の生成　／　報酬 r：人間の評価スコア

- Q6 のロボットと同じ構造：**行動（＝応答文）→ 報酬（＝人間の評価）**
- まず大量のテキストで言語モデルを事前訓練（教師あり的）
- その後，人間が「良い／悪い」とスコアを付け，それを報酬に方策を改善
- ChatGPT, Claude 等で使われている仕組み